

Reidentificação de Indivíduos em Diferentes Câmeras usando Soft Biometrics

André Franco Raineri¹,

Francesco Zangrandi Coppola¹,

Prof. Dr. Fabio Kawaoka Takase³

¹Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

10403340@mackenzista.com.br

10390470@mackenzista.com.br

fabio.takase@mackenzie.com.br

Resumo. *Sistemas de vigilância modernos geram um grande volume de vídeo, tornando desafiadora a tarefa de encontrar manualmente uma pessoa específica em meio a milhares de horas de gravações. Um cenário típico envolve a busca por uma pessoa de interesse, como por exemplo uma criança que se perdeu, com base em descrição. Atualmente, essa busca é realizada de forma majoritariamente manual, com operadores analisando múltiplas câmeras por horas. Além de ser um processo lento e sujeito a falhas humanas, a busca manual pode não abranger toda a vasta quantidade de dados disponível. Surge, portanto, a necessidade de automatizar a reidentificação de indivíduos em diferentes câmeras e momentos, utilizando descrições textuais para localizar ocorrências de uma pessoa de interesse em uma base de dados, dentro de uma área específica e em um determinado intervalo de tempo.*

Palavras-chave: *Busca de pessoas por Descrição Textual, Processamento de Imagem, Processamento de Linguagem Natural (NLP), Reidentificação de Pessoas, Soft Biometrics, Vigilância Inteligente, Visão Computacional, YOLO.*

Abstract. *Modern surveillance systems generate a large volume of video, making it challenging to manually locate a specific person among thousands of hours of recordings. A typical scenario involves searching for a person of interest, such as a lost child, based on a description. Currently, this search is mostly performed manually, with operators reviewing multiple cameras for hours. In addition to being a slow process and prone to human error, manual*

search may not cover the entire vast amount of available data. Therefore, there is a need to automate the re-identification of individuals across different cameras and times, using textual descriptions to locate occurrences of a person of interest within a database, in a specific area and within a given time interval.

Keywords: *Person Search by Textual Description, Image Processing, Natural Language Processing (NLP), Person Re-identification, Soft Biometrics, Intelligent Surveillance, Computer Vision, YOLO.*

1. Introdução

Sistemas de vigilância modernos geram um grande volume de vídeo, tornando desafiadora a tarefa de encontrar manualmente uma pessoa específica em meio a milhares de horas de gravações. Um cenário típico envolve a busca por uma pessoa de interesse, como por exemplo uma criança que se perdeu, com base em descrição. Atualmente, essa busca é realizada de forma majoritariamente manual, com operadores analisando múltiplas câmeras por horas. Além de ser um processo lento e sujeito a falhas humanas, a busca manual pode não abranger toda a vasta quantidade de dados disponível. Surge, portanto, a necessidade de automatizar a reidentificação de indivíduos em diferentes câmeras e momentos, utilizando descrições textuais para localizar ocorrências de uma pessoa de interesse em uma base de dados, dentro de uma área específica e em um determinado intervalo de tempo

A **definição do problema** abrange a reidentificação de pessoas em um conjunto de câmeras não sobrepostas, em uma faixa de tempo determinada, sem depender de identificadores biométricos rígidos (como rosto ou impressões digitais). Em vez disso, o foco recai sobre os *soft biometrics* – atributos físicos e comportamentais sutis, como vestuário, gênero, estatura, cor do cabelo, dentre outros. A **delimitação** do trabalho exclui técnicas de reconhecimento facial ou outros biométricos primários, concentrando-se naqueles atributos visíveis que não identificam univocamente uma pessoa, mas fornecem pistas para diferenciá-la na multidão (Dantcheva et al, 2016). Esses atributos, embora *indistintos e não permanentes* (por exemplo, várias pessoas podem usar camisa azul, e uma mesma pessoa pode trocar de roupa ao longo do dia), servem como evidências adicionais valiosas para reduzir a dimensão da busca. A escolha por utilizar *soft biometrics* também está fundamentada em preocupações éticas e legais, especialmente no que diz respeito à privacidade. Ao evitar o uso de traços que possibilitam a identificação direta de um indivíduo e inequívoca, reduz-se o risco de violações de direitos de privacidade, uma vez que se evita a coleta de informações que poderiam ser classificadas como dados sensíveis, previstos na Lei Geral de Proteção de Dados Pessoais (BRASIL, 2018). Dessa forma, o sistema proposto minimiza os riscos associados ao tratamento de dados pessoais sensíveis, ao mesmo tempo em que possibilita a indexação de gravações de vídeo, permitindo que consultas baseadas em descrições de atributos retornem as aparições possivelmente correspondentes à pessoa de interesse.

Objetivo Geral: Desenvolver um sistema de reidentificação de pessoas que, a partir de uma descrição semântica, seja capaz de localizar e indexar segmentos de vídeo nos quais uma pessoa de interesse aparece, mesmo quando capturada por diferentes câmeras, com ângulos de visão distintos, durante um determinado período, utilizando *soft biometrics*.

Objetivos Específicos:

- Implementar um *módulo de detecção* de pessoas em vídeo em tempo real, utilizando técnicas de visão computacional (detector YOLO) para identificar *frames* contendo pessoas.
- Desenvolver um *módulo de identificação* de pessoas de interesse baseado na extração de atributos (*soft biometrics*) como cor da roupa (parte superior e inferior), gênero aproximado, faixa de altura/estatura, cor de pele e outras características distintivas relevantes.
- Integrar os módulos de detecção e identificação em um sistema unificado capaz de realizar a recuperação de imagens/vídeos a partir de uma consulta, por meio de uma descrição textual dos atributos do indivíduo (consulta semântica), retornando todas as correspondências por meio de clips ou atributos anotados(câmera, time Stamp etc.).
- Avaliar o desempenho do sistema utilizando bases de dados anotadas e cenários simulados/ práticos, medindo métricas como precisão na recuperação (recall de aparições corretas) e taxa de falsos positivos, a fim de validar a eficácia da abordagem proposta.

As **contribuições** esperadas deste trabalho incluem: (1) a implementação de um protótipo funcional de sistema de vigilância inteligente capaz de realizar reidentificação de pessoas de interesse baseada exclusivamente em uma descrição semântica, e (2) benefícios para a sociedade, ao disponibilizar tecnologias que auxiliem órgãos de monitoramento na localização de pessoas de interesse traz diversos benefícios para a sociedade. Entre eles, destaca-se a possibilidade de realizar buscas de forma mais rápida e precisa, reduzindo significativamente o tempo necessário para análise manual de vídeos. Isso, por sua vez, contribui para a diminuição de riscos associados à demora na localização de indivíduos, como em casos de desaparecimentos, além de reduzir os custos operacionais envolvidos nesse tipo de busca. Em suma, o trabalho propõe um avanço em sistemas de segurança, ao integrar detecção por vídeo e atributos humanos (*soft biometrics*) para reidentificação de indivíduos através de múltiplas câmeras e ocasiões.

2. Referencial Teórico

2.1 Soft Biometrics:

O termo *soft biometrics* refere-se a atributos pessoais e físicos que, diferentemente de identificadores biométricos rígidos (*hard biometrics*) como impressões digitais, íris ou face, não identificam univocamente um indivíduo, mas fornecem informações complementares sobre sua aparência. Exemplos de *soft biometrics* incluem gênero, faixa etária, altura, peso, cor dos olhos, cor do cabelo, tons de pele, estilo e cor das roupas, tatuagens ou cicatrizes visíveis, entre outros (Dantcheva et al. (2016)). Esses atributos podem ser extraídos a partir de dados biométricos primários (por exemplo, estimar gênero e idade a partir de uma imagem facial) e têm aplicações importantes em vigilância e na indexação de bases de dados biométricos. Embora não sejam permanentes nem suficientemente distintos para autenticar alguém com alta confiabilidade isoladamente (Jain, Dass e Nandakumar (2004)), os *soft biometrics* mostram-se úteis quando combinados a identificadores primários – por exemplo, para filtrar candidatos em uma busca ou melhorar a acurácia de reconhecimento quando fundidos a algoritmos tradicionais. Dantcheva et al. (2016) destacam também que esses atributos fornecem uma forma de descrição qualitativa de indivíduos (e.g., "mulher jovem asiática de cabelos castanhos") que ajuda a **transpor a lacuna semântica entre as descrições humanas e a interpretação automática de dados biométricos**. Ou seja, *soft biometrics* permitem que sistemas computacionais lidem com descrições em linguagem natural ou atributos semânticos da mesma forma que um humano descreve uma pessoa, tornando-os particularmente valiosos para vigilância baseada em descrição ao invés de identidade conhecida.




Figura 1: Diferenciações de Biometrics.

Fonte: Galiyawala et al, 2021?

Historicamente, o uso de atributos físicos para identificação remonta ao final do século XIX com o sistema de Bertillon para identificação criminal, que catalogava indivíduos por medidas antropométricas (altura, comprimento dos braços etc.), características morfológicas (cor dos olhos, formato do rosto) e marcas singulares (cicatrices, tatuagens). Apesar de pioneira, a metodologia de Bertillon apresentava alta taxa de erro, pois muitos indivíduos podiam compartilhar as mesmas medidas e características, além destas mudarem ao longo do tempo. Este fato ilustra uma limitação central dos *soft biometrics*: isoladamente, eles não conseguem atingir a confiabilidade necessária para identificação única em aplicações críticas (Jain, Dass e Nandakumar (2004)). Ainda assim, conforme Jain et al. (2004) propuseram, a integração de atributos suaves com sistemas biométricos principais pode aumentar a eficiência e acurácia – por exemplo, restringindo a busca em uma base apenas ao subconjunto de pessoas do gênero e faixa de altura correspondentes ao suspeito, reduzindo drasticamente o número de comparações necessárias. Wayman (2004) também sugeriu o uso de traços como idade e gênero para filtrar grandes bases biométricas antes da verificação detalhada, melhorando a velocidade sem degradar significativamente o desempenho se aplicado corretamente. Essas ideias embasam o uso contemporâneo de *soft biometrics* como uma camada de **indexação e busca** em sistemas de vigilância – exatamente o foco do presente trabalho.

2.2 Reidentificação de Pessoas (Person Re-ID):

A reidentificação de pessoas é um problema de visão computacional que busca reconhecer a mesma pessoa através de diferentes câmeras ou em diferentes momentos, mesmo quando não há continuidade temporal direta. Em ambientes reais de CCTV, câmeras distintas capturam ângulos e iluminações diversos, e uma pessoa pode aparecer em resoluções baixas ou parcialmente oclusa por outros objetos ou pessoas. Essas variações de pose, iluminação, ponto de vista e qualidade das imagens tornam o *person re-id* um grande desafio técnico. Abordagens tradicionais de reidentificação envolvem extrair *features* visuais discriminativas do pedestre (por exemplo, descritores de cor e textura da roupa, ou vetores de características gerados por redes neurais profundas) e compará-las entre imagens para determinar se correspondem ao mesmo indivíduo. Nos últimos anos, métodos de *Deep Learning* (aprendizado profundo) treinaram redes neurais siamesas ou modelos de classificação com milhares de identidades para aprender embeddings robustos de aparência, capazes de agrupar fotos da mesma pessoa mesmo sob mudanças de câmera. Contudo, esses métodos geralmente exigem que as pessoas a serem reconhecidas apareçam previamente em um conjunto de treino (ou seja, precisam de uma “matrícula” prévia das identidades) para atingir alta acurácia. Na prática, isso significa que se um suspeito nunca foi visto ou cadastrado no sistema com imagens de referência, os métodos tradicionais de reidentificação falham em encontrá-lo apenas a partir de características visuais, devido à falta de um modelo prétreinado para aquela identidade, Conforme Halstead et al. (2018).

Em cenários de segurança do mundo real, muitas vezes não se dispõe de imagens prévias do indivíduo procurado – tem-se apenas a descrição de testemunhas ou uma imagem capturada de uma câmera específica a ser usada como consulta. Nesses casos, **buscas baseadas em atributos semânticos** emergem como solução viável. Halstead et al. (2018) enfatizam que técnicas de busca semântica por descrição textual eliminam a dependência de uma imagem de referência pré-cadastrada, permitindo procurar uma pessoa no acervo de vídeos a partir apenas de informações como vestuário e características físicas relatadas. Esse paradigma levou ao surgimento de competições e *benchmarks* específicos. Em 2018, a IEEE AVSS lançou um desafio internacional de *Semantic Person Retrieval*, com duas tarefas: (1) reidentificação de pessoa em uma galeria de imagens a partir de uma **consulta semântica textual**, e (2) busca por uma pessoa específica dentro de um vídeo, também guiada por uma descrição textual. Para suportar essas tarefas, os organizadores disponibilizaram uma base de dados anotada com atributos semânticos (*soft biometrics*) de indivíduos, bem como protocolos de avaliação padronizados, impulsionando a pesquisa nessa área emergente. Nesse desafio, cada indivíduo possuía até 16 atributos descritivos (como gênero, cor e tipo de roupa superior e inferior, uso de acessórios etc.), totalizando 55 valores possíveis distintos que compõem o perfil semântico da pessoa. A criação desse tipo de *benchmark* evidencia tanto a importância prática quanto a dificuldade do problema: métodos automatizados precisam ser capazes de interpretar consultas textuais e compará-las com representações visuais de pessoas nunca vistas anteriormente.

2.3 Busca de Pessoas por Texto:

A busca de pessoas com base em descrições textuais (também chamada de *text-based person search*) é uma extensão do problema de reidentificação que envolve recuperação por meio de linguagem natural. Formalmente, dada uma descrição textual livre de um indivíduo, o objetivo é **recuperar, dentre um grande conjunto de imagens de pedestres, aquelas que correspondem à pessoa descrita**, classificando os resultados por relevância. Essa tarefa combina os desafios da reidentificação visual com os de recuperação multimodal, pois é necessário lidar com a diferença intrínseca entre as modalidades texto e imagem. De um lado, é preciso extrair das imagens características robustas a mudanças de pose, iluminação e oclusões. De outro, é necessário interpretar a descrição textual e transformá-la em uma representação comparável às características visuais. Existe, portanto, uma **lacuna semântica** entre as palavras usadas para descrever uma pessoa e os atributos visuais mensuráveis nas imagens (GALIYAWALA; RAVAL, 2021). Os *soft biometrics* atuam justamente como ponte nessa lacuna. Uma descrição do tipo "uma mulher baixa, vestindo camiseta rosa e saia branca, carregando uma bolsa preta" contém diversos atributos que podem ser detectados visualmente: gênero feminino, baixa estatura, roupa superior de cor rosa, roupa inferior branca, acessório bolsa preta, cabelo castanho etc. (Halstead et al. (2018)). Todos esses detalhes textuais nada mais são do que *soft biometrics* expressos em linguagem natural, os quais podem ser extraídos e comparados com as detecções no vídeo (GALIYAWALA; RAVAL, 2021). Em outras palavras, a consulta textual fornece um conjunto de atributos semânticos que o sistema de visão precisa buscar nas imagens de pedestres.

Pesquisas recentes focam em **representações conjuntas texto-imagem** que preservem esses atributos semânticos. Uma abordagem eficaz é projetar um espaço de embedding comum onde tanto a descrição em texto quanto a imagem de um pedestre sejam mapeadas, de forma que descrições correspondentes fiquem próximas de suas imagens na métrica desse espaço (Aggarwal et al., 2020). Para alcançar isso, métodos como o de Aggarwal et al. (2018) propõem o aprendizado multitarefa que inclui a predição de atributos visuais a partir das imagens, além da correspondência texto-imagem. Os atributos funcionam como um recurso intermediário **invariante à modalidade** – isto é, independem de ser texto ou imagem, representando conceitos universais como “masculino”, “jaqueta vermelha”, “calça jeans azul” que podem ser reconhecidos em ambos os domínios (Aggarwal et al., 2020). Isso auxilia o modelo a aprender a associar partes da descrição textual (ex: “jaqueta vermelha”) com partes da imagem (a região superior vermelha do pedestre) de forma explícita. Além disso, diferente de identificadores únicos (rótulos de identidade), que se limitam às identidades vistas na fase de treinamento, os atributos são aplicáveis mesmo a pessoas nunca vistas pelo sistema, generalizando para novos casos. Em suma, atributos semânticos fornecem uma representação **humanamente interpretável e transferível** para descrever pessoas, o que tem se mostrado crucial na busca de pessoas por texto. De fato, incorporando atributos, Aggarwal et al. alcançaram **56,68% de acurácia Rank-1** no conjunto de dados CUHK-

PEDES (um *benchmark* de descrição textual), superando abordagens que não usam esse recurso e estabelecendo um novo patamar para a tarefa.

Conforme Galiyawala e Raval (2021) apontam em sua revisão, o campo de recuperação de pessoas por consultas textuais evoluiu rapidamente, contando hoje com diversas arquiteturas e conjuntos de dados de teste. Sua pesquisa de revisão compila as abordagens desde métodos com *features* manuais até estratégias de ponta com redes neurais profundas baseadas em descrições naturais, e avalia o desempenho de diferentes combinações de atributos. Entre as conclusões, destaca-se que certos atributos tendem a ser mais discriminativos conforme o contexto: por exemplo, a cor da roupa e presença de itens como mochila podem ser críticos em ambientes urbanos diurnos, enquanto detalhes como altura ou porte físico podem ganhar importância em cenários noturnos de baixa resolução onde cores são menos visíveis (GALIYAWALA; RAVAL, 2021). Além disso, o estudo integrador desses autores reúne os principais *datasets* disponíveis (como CUHK-PEDES, Market-1501 Attributes, DukeMTMC-attribute, RAP, entre outros) e os algoritmos de recuperação, proporcionando uma referência objetiva de desempenho entre eles. Essa visão geral reforça que, embora muito progresso tenha sido feito, **a recuperação de pessoas por atributos permanece um desafio aberto**, especialmente diante de condições adversas de vigilância. A pesquisa atual indica que combinar múltiplos atributos (*soft biometrics*) de forma estratégica – possivelmente junto a modelos de detecção e rastreamento robustos – é o caminho para aumentar a precisão na reidentificação sem recorrer a identidades pré-definidas.

3. Metodologia

Nesta seção, é detalhada a abordagem metodológica proposta para atingir os objetivos delineados. Em resumo, o sistema será dividido em **três componentes principais**: (1) detecção de pessoas em vídeo, (2) extração dos atributos semânticos (*soft biometrics*) de cada pessoa detectada, e (3) indexação das aparições e mecanismo de busca/recuperação conforme a consulta do usuário. A implementação será realizada majoritariamente em Python, utilizando bibliotecas e *frameworks* de visão computacional e aprendizado de máquina, dada a ampla disponibilidade de ferramentas nesse ecossistema para as tarefas propostas.

3.1 Detecção de Pessoas (Person Detection)

Para identificar e extrair regiões de imagem correspondentes a pessoas dentro dos vídeos de vigilância, será utilizada a técnica de detecção de objetos baseada em redes neurais convolucionais. Em particular, optou-se pelo algoritmo **YOLO (You Only Look Once)** devido à sua eficiência e acurácia em detecção em tempo real.

O YOLO realiza a detecção e classificação de objetos (no caso, pessoas) em uma única passada pela imagem, o que o torna capaz de processar vídeo quadro a quadro rapidamente. Versões modernas do YOLO (como YOLOv5, YOLOv7 ou YOLOv8) oferecem melhorias em precisão e velocidade; estudos recentes demonstram desempenho promissor dessas versões para detecção de pedestres, inclusive sob condições de multidão (crowd) e oclusões. Inicialmente, será empregada uma versão pré-treinada do YOLO (por exemplo, treinada no conjunto COCO, que já inclui a classe “person”) para realizar a detecção de todos os pedestres em cada *frame* dos vídeos fornecidos. Dependendo da taxa de quadros e redundância, poderemos aplicar a detecção em cada n frames (por exemplo, 1 em cada 5 frames) para reduzir processamento, assumindo que pessoas em movimento contínuo serão detectadas em pelo menos um desses quadros. Cada detecção resultará em uma *bounding box* delimitando a pessoa e um grau de confiança. Técnicas de supressão de não-máximos serão usadas para filtrar detecções duplicadas. Além disso, se necessário, será empregada uma etapa de **rastreamento multi-objetos** (por exemplo, utilizando algoritmos como SORT/DeepSORT) para associar detecções consecutivas da mesma pessoa dentro de um mesmo vídeo/câmera, evitando contabilizar a mesma pessoa duas vezes durante seu trajeto contínuo. Ao final desta etapa, teremos isolado, para cada indivíduo detectado, a imagem correspondente (recorte do frame original) e metadados como o identificador da câmera e carimbo de tempo (timestamp) daquele avistamento.

3.2 Extração de Atributos Semânticos:

Com as imagens de cada pessoa detectada, o próximo passo é extrair automaticamente os atributos descritivos relevantes. Esta etapa constitui o núcleo de utilização de *soft biometrics* no sistema. Será desenvolvida uma pipeline de reconhecimento de atributos que combina técnicas de visão computacional aprendizado profundo. Em virtude da variedade e natureza dos atributos, diferentes abordagens serão aplicadas a distintos grupos de atributos:

- **Cor de vestuário:** Para determinar as cores predominantes das roupas (por exemplo, camisa vermelha, calça jeans azul), serão exploradas tanto soluções baseadas em aprendizado quanto heurísticas de processamento de imagem. Uma abordagem inicial consiste em segmentar aproximadamente a imagem da pessoa em regiões correspondentes ao torso (roupa superior) e pernas (roupa inferior), o que pode ser estimado a partir da proporção da *bounding box* ou usando pontos-chave do corpo obtidos por um modelo de *pose estimation*. Em seguida, calcula-se a cor dominante em cada região através de histogramas de cor ou classificação em grupos de cores. Alternativamente, um modelo de rede neural convolucional pode ser treinado para classificar diretamente a cor da roupa superior e inferior. Bases de dados anotadas, como a **RAP (Richly Annotated Pedestrian)** que oferece **rótulos de cores e tipos de roupa** para milhares de imagens, as quais podem ser utilizadas para treinar ou adaptar um classificador de atributos de vestimentas (GALIYAWALA; RAVAL, 2021).
- **Gênero:** Características como gênero aparente (masculino/feminino) serão extraídas utilizando modelos preditores treinados para tal finalidade. Diversos trabalhos anteriores reportam acurácia elevada na predição de gênero a partir de imagens de corpo inteiro ou face. Como as faces podem não estar claramente visíveis nas imagens de vigilância, o classificador considerará pistas globais (vestuário, cabelo, porte físico) para inferir o gênero. Podemos aproveitar novamente bases anotadas (RAP inclui gênero como atributo) para treinar uma pequena rede neural (ou utilizar modelos pré-treinados) para essa tarefa.
- **Estatura (altura) e proporção corporal:** A altura absoluta de uma pessoa não pode ser determinada com precisão de uma única câmera sem referências métricas; entretanto, pode-se classificar a estatura de forma relativa (baixo, mediano, alto) com base em comparações com o ambiente ou informações de contexto. Alguns *datasets* de atributos rotulam indivíduos como “alta” ou “baixa” estatura de forma qualitativa, o que permite treinar um classificador de estatura relativa. No nosso caso, usaremos a proporção do corpo no vídeo e possivelmente dados de calibração da câmera (por exemplo, altura das câmeras) para auxiliar nessa inferência. De modo similar, atributos como tipo físicos (magro, atlético, corpulento) podem ser inferidos pela razão entre larguras de ombro/quadril e altura.

Tecnicamente, a extração de todos os atributos poderá ser unificada em um único modelo de Reconhecimento de Soft Biométrico. Para isso, será desenvolvida uma pipeline de reconhecimento de atributos que combina exclusivamente técnicas de visão computacional e heurísticas, gerando valor para cada característica previamente definida.

O processo se inicia com a detecção do indivíduo utilizando o modelo YOLO, após o que a imagem recortada do indivíduo é processada por um conjunto de métodos baseados em visão computacional e heurísticas específicas para a extração dos atributos. Esses métodos retornam um vetor de características semânticas, indicando os valores de cada atributo predefinido.

A validação do módulo de atributos será realizada por meio da comparação entre as predições obtidas e os valores reais presentes em um dataset de teste conhecido. Espera-se que o desempenho obtido seja compatível com os resultados reportados na literatura, onde acurácias para atributos individuais frequentemente superam 80% em casos de características visualmente evidentes, como gênero ou cor do vestuário. Por outro lado, atributos mais sutis, como faixa etária ou altura, podem apresentar desempenhos inferiores, dada a maior complexidade na sua inferência visual (Chaudhari et al., 2023).

3.3 Indexação e Recuperação

Com cada pessoa detectada, o sistema irá armazenar timestamp e meta dados sobre o clip em uma **base de dados indexada** criando efetivamente um índice pesquisável das gravações de vídeo. Cada entrada no banco de dados representará uma aparição de uma pessoa e conterá: (a) identificador do vídeo/câmera e timestamp da aparição, (b) um ID do evento para vincular múltiplos frames um evento contínuo, (c) informações sobre a câmera que fez a captura (localização, angulo, etc...), (d) uma imagem recortada (thumbnail) com o indivíduo em destaque, que poderá ser usada para uma visualização rápida dos resultados pelo usuário. Esses dados serão utilizados durante a consulta para a extração das características de cada pessoa na busca da pessoa de interesse.

A **consulta** ao sistema irá ocorrer pela descrição textual de uma pessoa, o usuário forneceria atributos desejados, seja preenchendo um formulário seguindo o padrão do código. Esses atributos serviriam então para realizar uma busca no banco: o motor de busca irá comparar a consulta com cada pessoa indexada e **ranquear** as pessoas por grau de correspondência.

A correspondência entre indivíduos pode ser inicialmente definida com base no número de atributos coincidentes. No entanto, é possível atribuir pesos distintos a cada atributo conforme sua confiabilidade e relevância no contexto. Por exemplo, a cor da roupa pode receber um peso maior que a faixa etária, caso seja considerada uma característica mais distintiva na situação analisada.

Além disso, serão utilizados dados referentes à configuração espacial das câmeras, com o objetivo de viabilizar a aplicação em um sistema de vigilância real, onde tais informações estão disponíveis. Esses dados permitirão avaliar a viabilidade temporal do deslocamento de uma pessoa entre diferentes câmeras. Por exemplo, se o tempo médio de deslocamento entre a câmera 1 e a câmera 2 for de 10 minutos, mas um indivíduo é identificado na câmera 2 imediatamente após desaparecer da câmera 1, pode-se inferir que se trata de pessoas diferentes.

Em termos de implementação prática, a base de dados poderá ser um banco **NoSQL** ou mesmo uma estrutura indexada em memória (como um dicionário ou um *dataframe* usando Pandas) para prototipagem. Para busca eficiente, técnicas de indexação invertida serão úteis: por exemplo, manter dicionários que, para cada valor de atributo (ex: “camisa_vermelha”) apontem para lista de IDs de detecções que possuem esse atributo. Assim, uma consulta que especifique vários atributos pode rapidamente obter interseção das listas correspondentes. Entretanto, dada a escala de um projeto acadêmico e bases de teste moderadas, uma solução em Python puro será suficiente inicialmente.

3.4 Bases de Dados e Avaliação:

Durante o desenvolvimento, serão utilizadas bases de dados **anotadas publicamente** tanto para treinar os modelos de atributos quanto para avaliar o sistema. Conforme citado, a base **RAP** contém mais de 41.000 imagens de pedestres anotadas com 69 atributos binários (incluindo vestuário, gênero, idade aparente, acessórios) coletados de câmeras reais, sendo um recurso valioso para treinar o módulo de reconhecimento de atributos. Já a base disponibilizada pelo **AVSS 2018 Challenge II** traz sequências de vídeo curtas e descrições semânticas textuais dos indivíduos, alinhadas ao problema de busca por descrição. Pretende-se usar parte desses dados para simular cenários de vigilância: por exemplo, utilizar alguns vídeos como *galeria* e descrever uma pessoa consultada para ver se o sistema a recupera corretamente. A métrica de sucesso principal será a **taxa de acerto na recuperação** – por exemplo, dada uma consulta (texto ou imagem), se o sistema retornar o mesmo indivíduo correto entre os top N resultados. No caso de consultas textuais, podemos medir *Rank-1 accuracy* ou *Recall*, alinhado com protocolos de pesquisas anteriores. Já para consultas por clip, mediremos quantas aparições daquela pessoa em outras câmeras foram encontradas (recall) e se poucas falsos positivos aparecem (precision). Também serão registradas métricas de desempenho computacional, como o tempo necessário para processar

determinadas quantidades de vídeo (por exemplo, X horas) e o tempo de resposta a consultas. Contudo, essa avaliação será realizada em um escopo reduzido, com o objetivo exclusivo de demonstrar a viabilidade do sistema em um cenário de uso real.

Em síntese, a metodologia combina algoritmos de **visão computacional** para detecção com técnicas de **reconhecimento de atributos** e **processamento de linguagem natural**, integrando-os em um fluxo coerente. Essa estratégia de múltiplos subsistemas espelha soluções end-to-end recentes propostas na literatura [31](#), adaptando-as ao escopo acadêmico do TCC. A seguir, apresentamos o cronograma estimado para a execução do projeto, abrangendo as etapas de implementação e avaliação descritas.

4. Cronograma

Próximos passos	Jun	Jul	Ago	Set	Out
Realizar revisão bibliográfica e preparar o ambiente de desenvolvimento, incluindo instalação de ferramentas e coleta de bases de dados.	X				
Implementar o módulo de detecção de pessoas utilizando YOLO e iniciar testes preliminares em vídeos de exemplo.	X	X			
Desenvolver o módulo de extração de atributos soft biometrics e integrá-lo ao sistema de detecção.		X	X		
Implementar a indexação das detecções e desenvolver a interface de consulta textual para busca no banco de dados.				X	
Realizar testes finais, ajustes no sistema, documentação completa e preparação para a apresentação do TCC.					X

O cronograma do projeto foi organizado ao longo de cinco meses, de junho a outubro, de forma sequencial e estruturada, garantindo o desenvolvimento gradual e completo do sistema de reidentificação de pessoas baseado em *soft biometrics*.

No **mês de junho**, as atividades se concentram na **revisão bibliográfica e preparação do ambiente de desenvolvimento**. Nessa etapa, serão pesquisadas as principais técnicas de reidentificação de pessoas, detecção de atributos semânticos e uso de redes neurais como o YOLO, além de realizar o levantamento de ferramentas e bibliotecas adequadas. Em paralelo, será configurado todo o ambiente técnico: instalação de Python, frameworks de deep learning (TensorFlow ou PyTorch), OpenCV, e organização dos datasets que serão utilizados na fase prática.

Em **julho**, o foco será na **implementação do módulo de detecção de pessoas utilizando o modelo YOLO**. Esta etapa consiste em adaptar ou treinar o modelo para identificar corretamente pessoas nas imagens de vídeos de vigilância, garantindo que as detecções sejam precisas. Simultaneamente, será iniciado o desenvolvimento do **módulo de extração de atributos semânticos** (soft biometrics), começando pela definição dos atributos que o sistema deverá reconhecer (como cor de roupa, gênero, altura) e pela organização de dados para treinar classificadores especializados.

No **mês de agosto**, o trabalho será dedicado à **conclusão do módulo de extração de atributos**, finalizando o treinamento dos classificadores e validando sua acurácia. Ao término dessa etapa, o sistema será capaz não apenas de detectar pessoas, mas também de extrair automaticamente características descritivas de cada indivíduo. Essa capacidade permitirá que o sistema produza perfis semânticos que servirão de base para consultas posteriores.

Durante o **mês de setembro**, ocorrerá a **integração dos módulos desenvolvidos** — o de detecção de pessoas e o de extração de atributos — em um sistema coeso. Além disso, será implementado o **mecanismo de indexação**, criando uma base de dados estruturada onde cada pessoa detectada será registrada com seus respectivos atributos e metadados. Concomitantemente, será realizada a **criação da interface de consulta**, que permitirá ao usuário realizar buscas por meio de descrições textuais ou imagens de referência, recuperando rapidamente ocorrências de interesse.

Por fim, em **outubro**, será realizada uma **rodada completa de testes e validação do sistema**, avaliando o desempenho em diferentes cenários, medindo métricas como precisão, revocação e eficiência. Com base nos resultados, serão feitos os **ajustes finais** para otimizar o funcionamento do sistema. Paralelamente, será elaborada a **documentação completa do projeto**, incluindo o relatório final (monografia), registros de testes e demonstrações, bem como a preparação para a apresentação do TCC, com slides e materiais de apoio.

Assim, o cronograma garante uma progressão lógica das atividades, partindo da fundamentação teórica até a entrega de um sistema funcional, bem testado e documentado, pronto para ser apresentado.

5. Referências bibliográficas

1. AGGARWAL, S.; BABU, R.V.; CHAKRABORTY, A. *Text-based Person Search via Attribute-aided Matching*. In: **2020 IEEE Winter Conference on Applications of Computer Vision (WACV)**. Los Alamitos: IEEE, 2020. p. 2606–2615.
2. DANTCHEVA, A.; ELIA, P.; ROSS, A. *What Else Does Your Biometric Data Reveal? A Survey on Soft Biometrics*. IEEE Transactions on Information Forensics and Security, v.11, n.3, p.441–467, 2016.
3. DENMAN, S.; HALSTEAD, M.; FOOKES, C.; SRIDHARAN, S. *Searching for people using semantic soft biometric descriptions*. Pattern Recognition Letters, v.68, p.306–315, 2015.
4. GALIYAWALA, H.; RAVAL, M. *Person retrieval in surveillance using textual query: a review*. Multimedia Tools and Applications, v.80, p.27343–27383, 2021.
5. HALSTEAD, M.; DENMAN, S.; FOOKES, C.; TIAN, Y.; NIXON, M. *Semantic Person Retrieval in Surveillance Using Soft Biometrics: AVSS 2018 Challenge II*. In: **15th IEEE International Conference on Advanced Video and Signal Based Surveillance (AVSS)**. Auckland, NZ: IEEE, 2018. p.1–6.
6. REDMON, J.; DIVVALA, S.; GIRSHICK, R.; FARHADI, A. *You Only Look Once: Unified, Real-Time Object Detection*. In: **Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)**. Las Vegas: IEEE, 2016. p.779–788.
7. Wayman, J. L.: Large-scale Civilian Biometric Systems - Issues and Feasibility. In: Proceedings of Card Tech / Secur Tech ID. (1997) 732
8. JAIN, A. K.; DASS, S. C.; NANDAKUMAR, K. Soft biometric traits for personal recognition systems. In: **INTERNATIONAL CONFERENCE ON BIOMETRIC AUTHENTICATION**, 1., 2004, Hong Kong. Lecture Notes in Computer Science, v. 3072. Berlin: Springer, 2004. p. 731–738.

